머신러닝을 쉽게 이해할 수 있을까요?

#분류문제 #머신러닝 #패키지 #훈련세트 #학습세트 #넘파이 #사이킷런

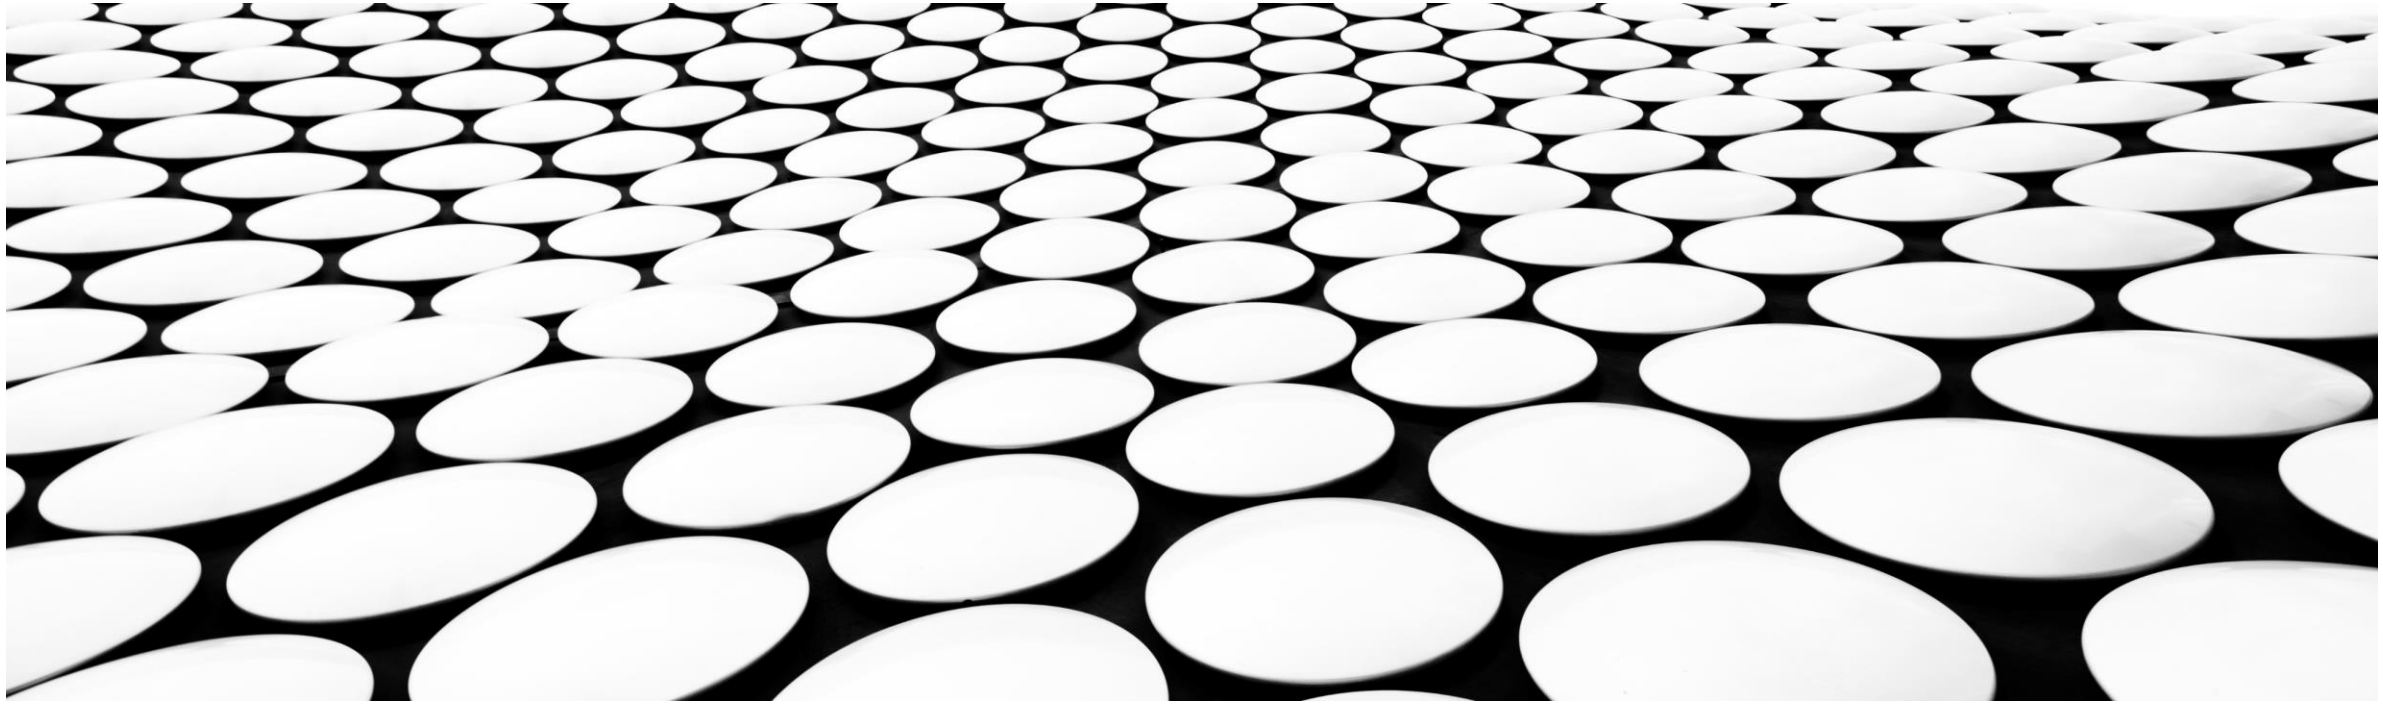

담당 강사 : 안상선 (sangsun.ahn@gmail.com)

Chapter01 : 변수와 데이터

1.1 변수와 자료

- 변수(Variable) : 연구자의 관심대상이 되는 성격 or 속성
- 자료(Data) : 이러한 변수를 관찰하여 기록한 결과

한 집단의 특성을 쉽게 알아보고 분석하기 위해서는 수집된 자료를 의미 있는 모양으로 분류· 정리하는 것이 중요하다.

1.2 자료의 종류

- 범주형 자료(질적, 비계량)
  - 명목변수(Nominal Variable) : 개체나 사람의 특성만 (성별, 종교 등)
  - 순서(서열)변수(Ordinal Variable) : 측정대상 간 선호를 부여 (선호도, 만족도)

- 양적인 자료(양적, 계량)
  - 등간변수(Interval Variable) : 측정대상 간의 순서 + 값 사이의 간격이 일정 (IQ,온도)
    절대 영점이 없음(100도는 50도의 2배 뜨겁다?)
  - 비율변수(Ratio Variable) : 측정대상 간에 비율 계산이 가능함(연령, 무게, 거리, 시간)
  - 이산형 변수(Discrete Variable) : 점수, 빈도수
  - 연속형 변수(Continuous Variable) : 실수, 키, 몸무게

1.2 자료의 종류

연속형 변수와 이산형 변수

- 연속형 변수 : 시간에 대해서 행동과 상태가 유한차원 벡터공간

  : 주가 수익률, 자동차의 운행거리,

- 이산형 변수 : 시간에 대해서 행동과 상태가 원소형태의 값(Value)를 갖는다.

  : {라이트를 켠다, 라이트를 끈다, 매도한다, 매수한다}

연속형 변수 : 수익률

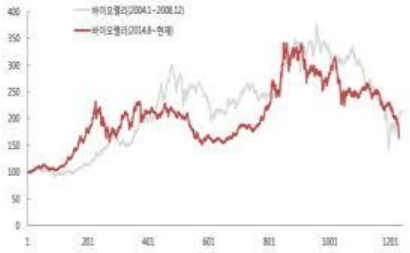

이산형 변수 : 전원 상태

Chapter02 : 인공지능을 활용한 데이터 분석

머신러닝과 딥러닝

Artificial Intelligence

인공지능

사고나 학습등 인간이 가진
지적 능력을 컴퓨터를 통해
구현하는 기술

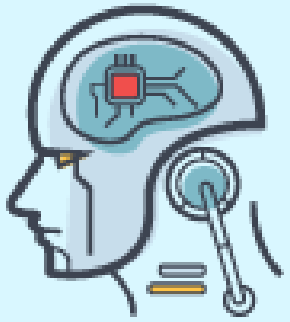

Machine Learning

머신러닝

컴퓨터가 스스로 학습하여
인공지능의 성능을
향상 시키는 기술 방법

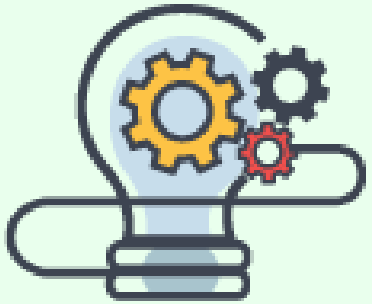

Deep Learning

딥러닝

인간의 뉴런과 비슷한
인공신경망 방식으로
정보를 처리

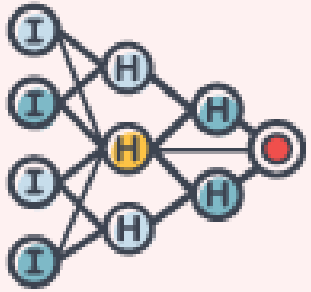

머신러닝과 딥러닝

그림4 머신러닝 VS 딥러닝

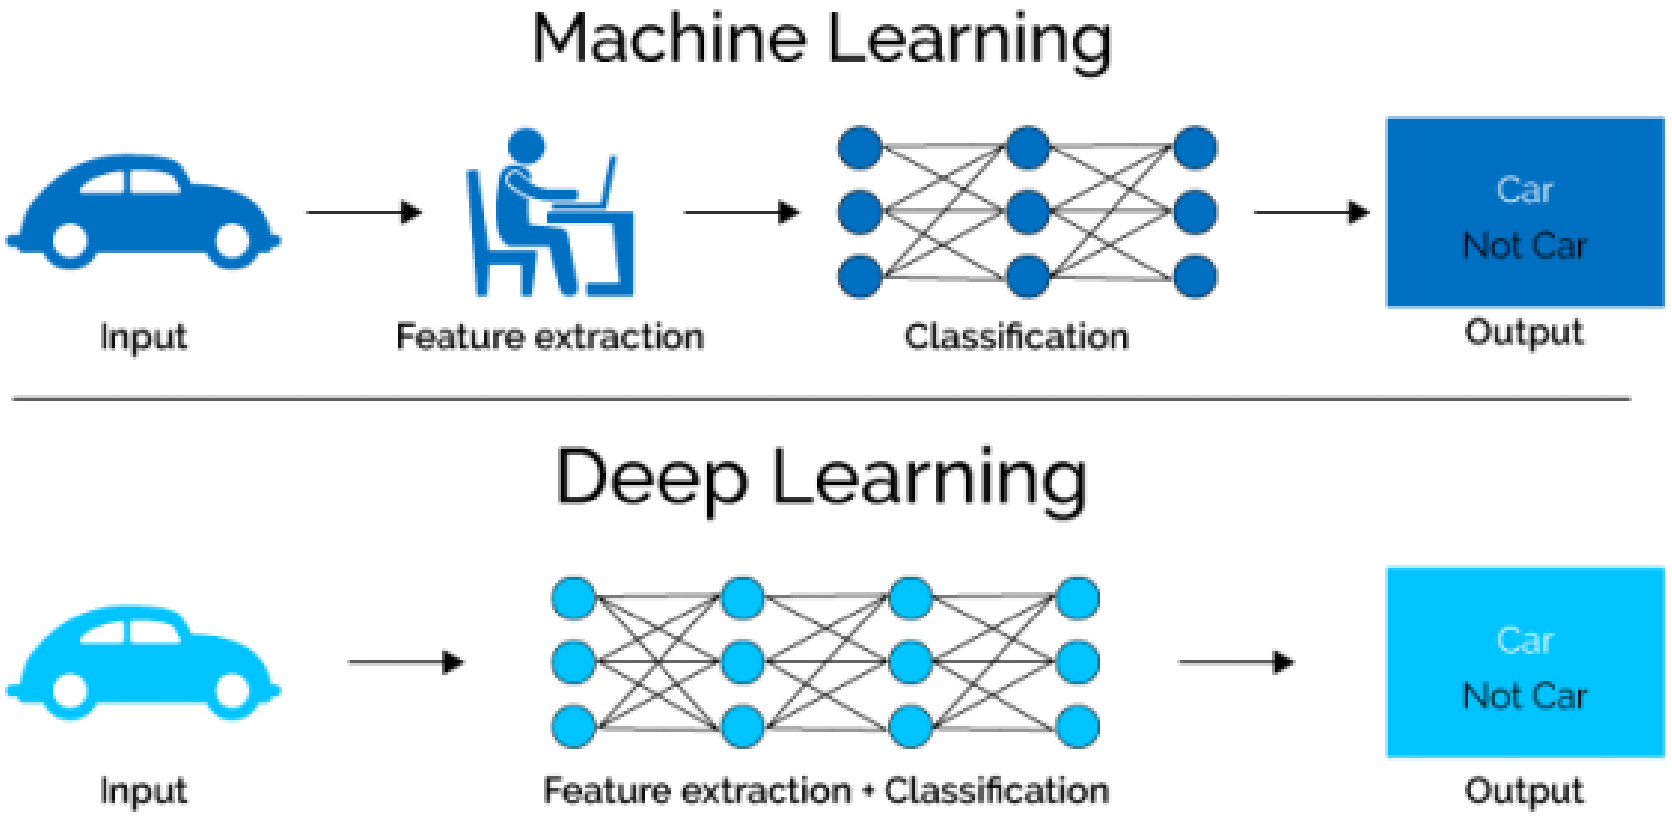

자료: Towards Data Science, 메리츠종금증권 리서치센터

예시 : 신용카드 부도 예측


연합뉴스
이슈 LUT
최고의 게임 망한 게임
갓겜과 망겜을 가르는 척도
'게임핵을 잡아라'
지도에 표시된 구역에서 경기가 진행됩니다

예시 : 강우량 예측

예시 : 신용카드 부도 예측

https://www.kaggle.com/mlg-ulb/creditcardfraud

Chapter01 : 신용카드 부도예측

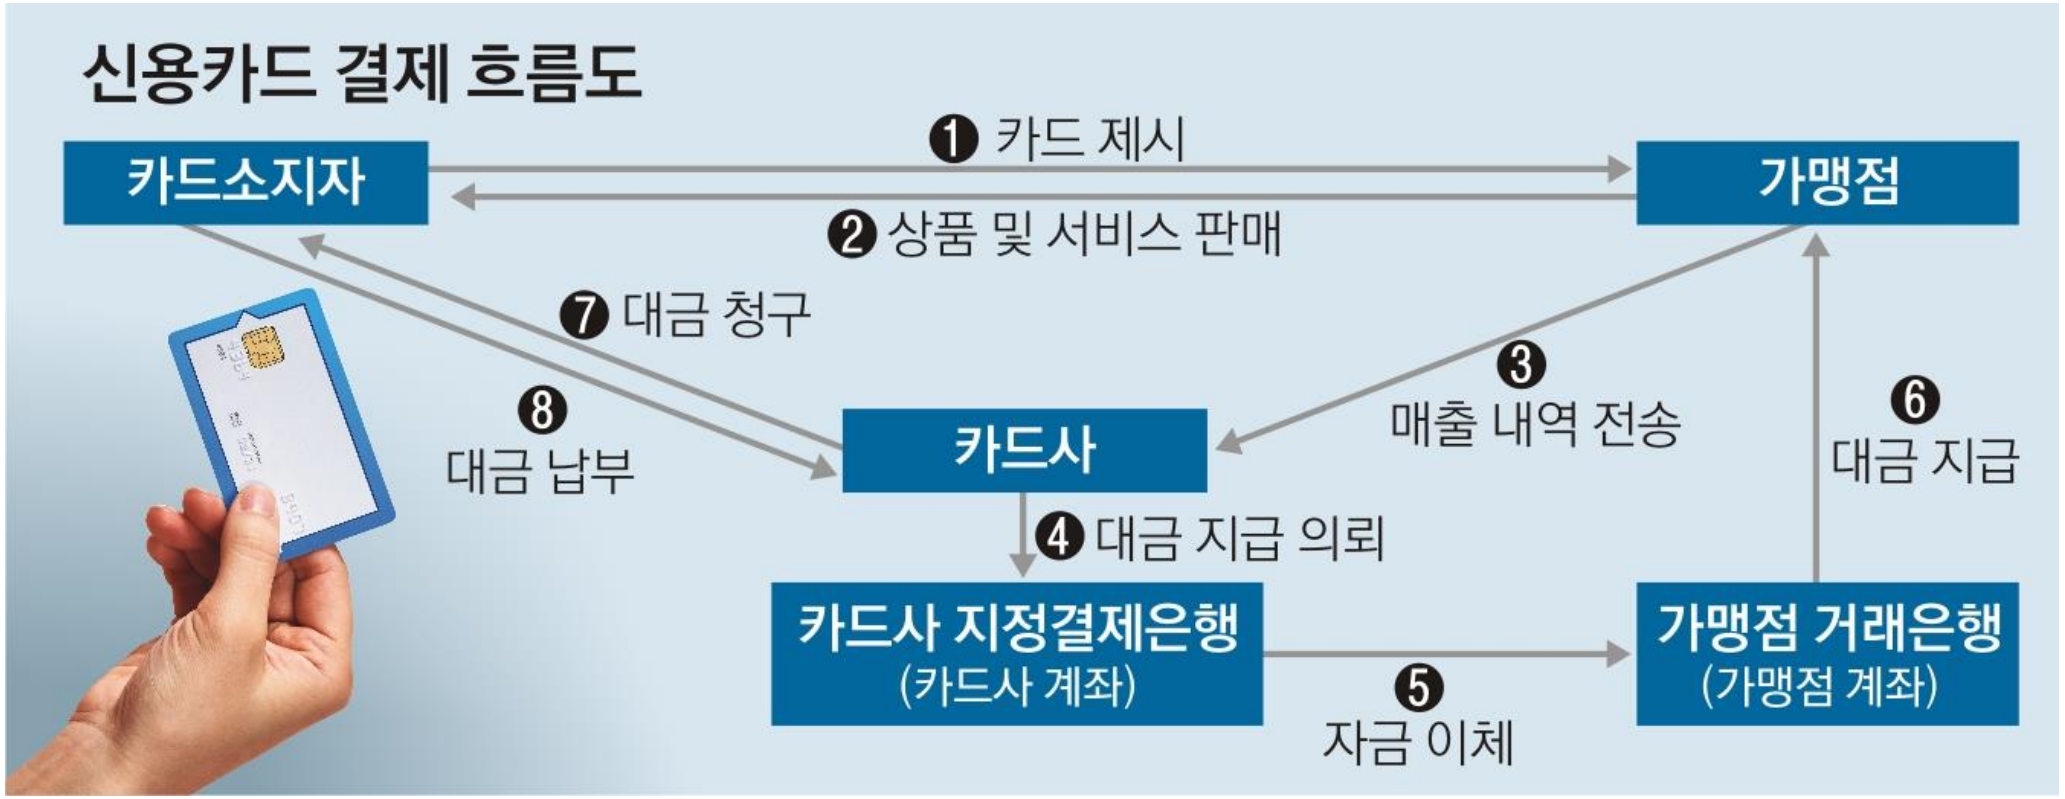

Chapter01 : 신용카드 부도예측

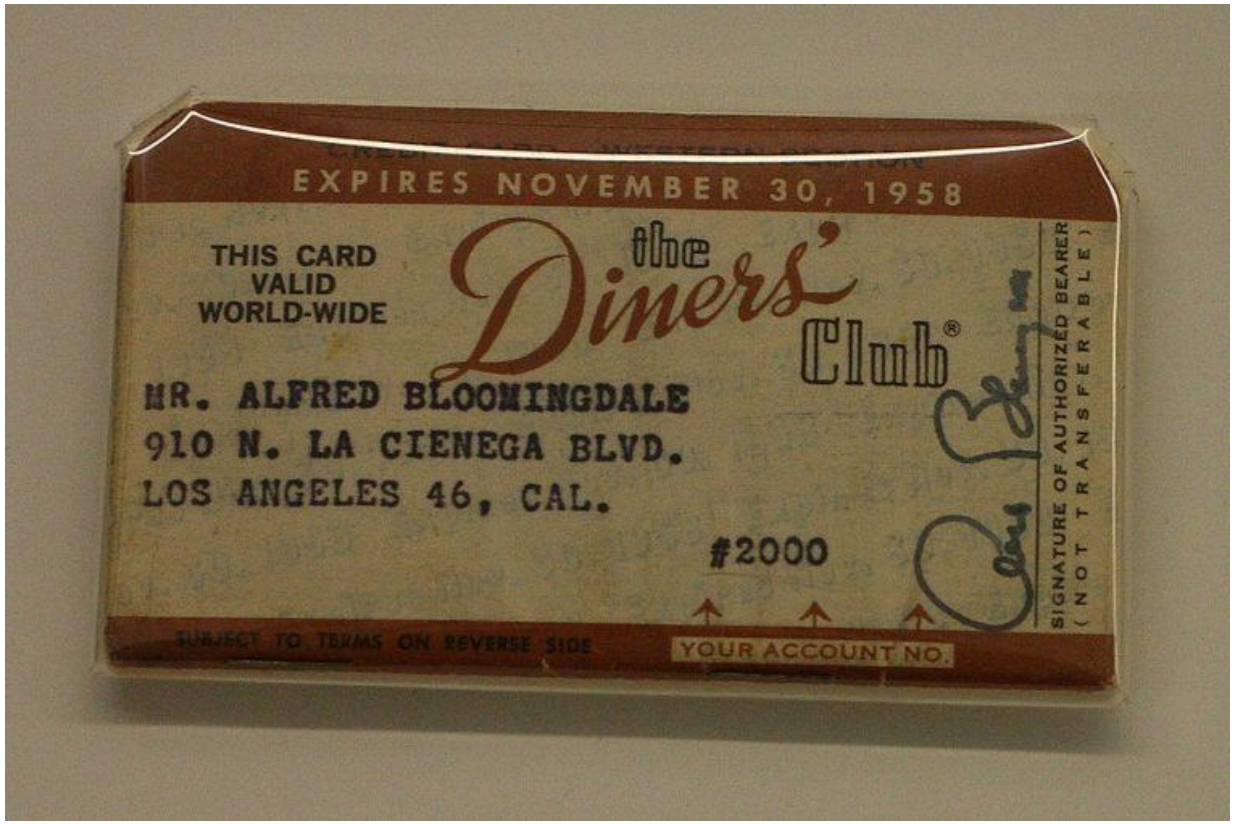

Chapter01 : 신용카드 부도예측

Chapter02 : 생선분류 문제

1> 생선 분류 문제

- 생선가게 : 생선은 가격 태그를 붙이기 어렵다.

- 편의점처럼 어떤 품목(생선종류)인지 또 가격(사이즈별 단가)을 알기 어려움

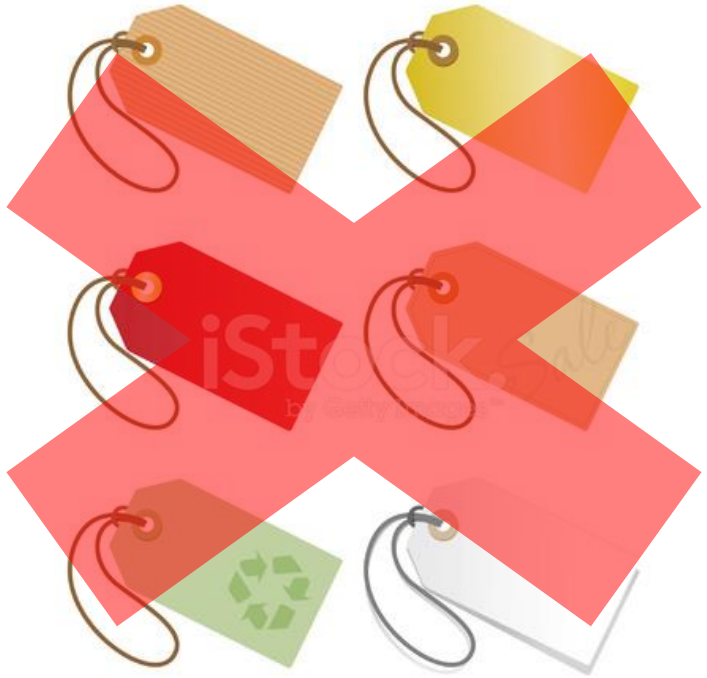

3> Data Set

- URL : https://www.kaggle.com/aungpyaeap/fish-market

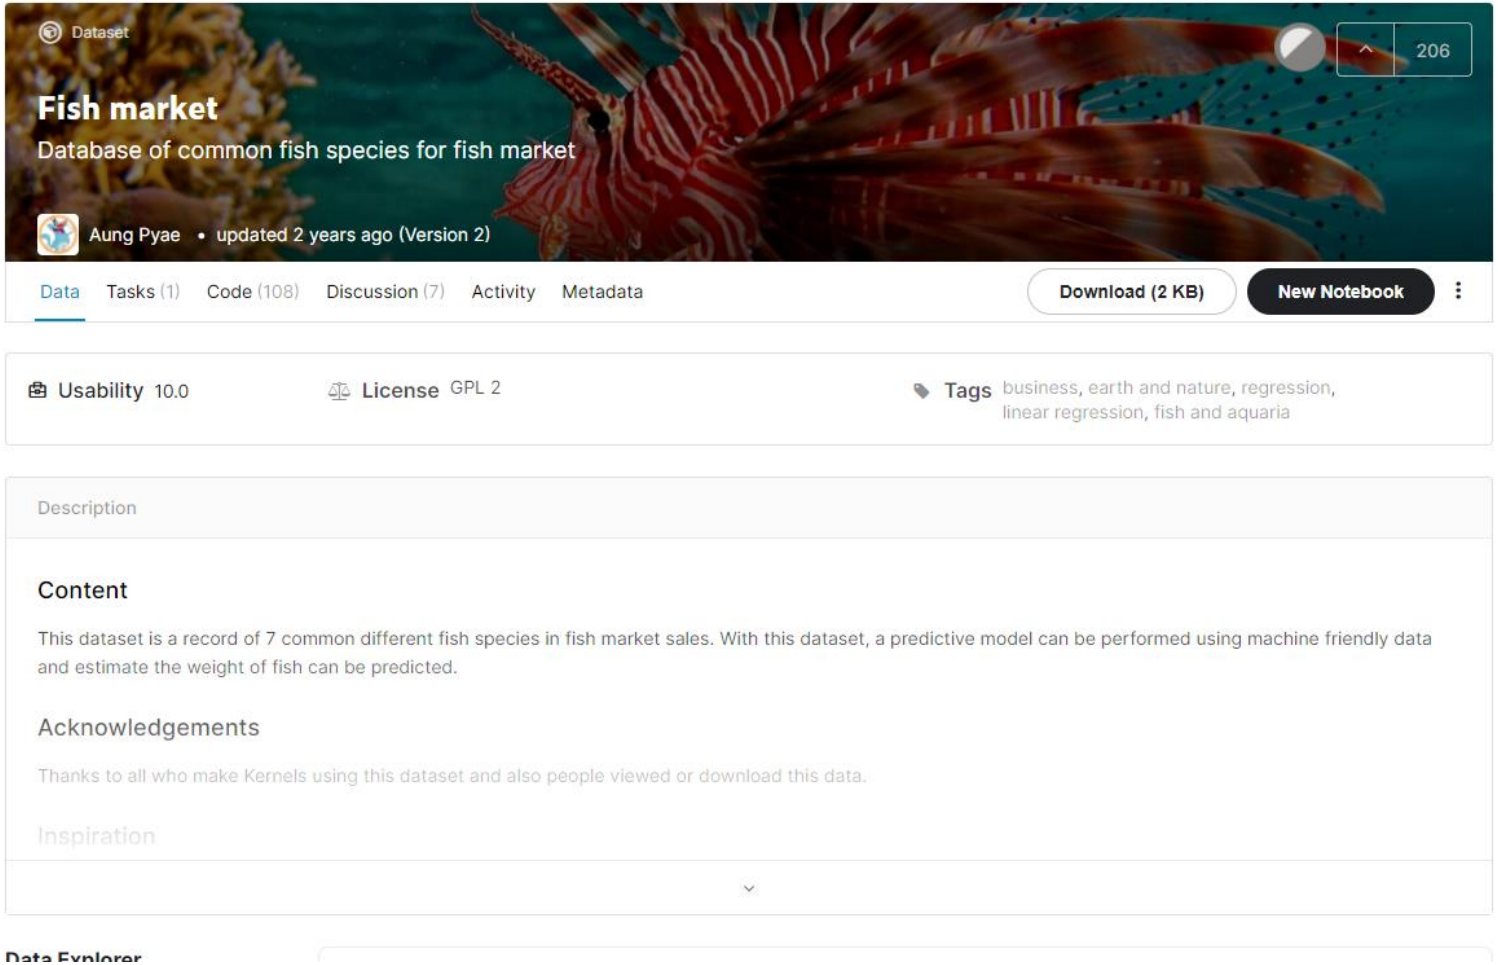

4> 사용 알고리즘 : K-means clustering

- 주어진 데이터를 k개의 클러스터로 묶는 알고리즘으로, 각 클러스터와 거리 차이의 분산을 최소화하는 방식으로 작동합니다.
- 이 알고리즘은 자율 학습의 일종으로, 레이블이 달려 있지 않은 입력 데이터에 레이블을 달아주는 역할을 수행합니다.

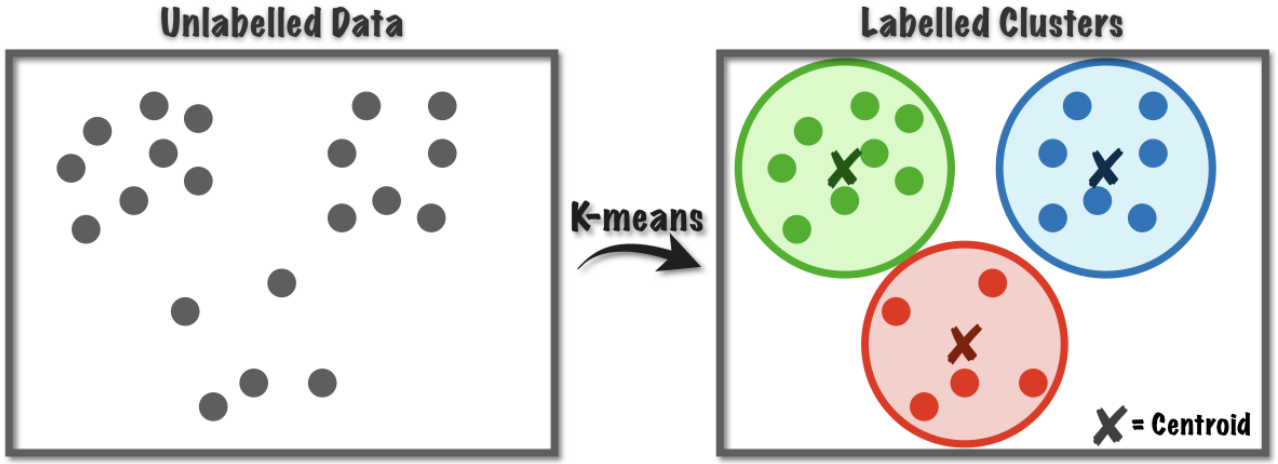

출처 : 위피키디아

4> 사용 알고리즘 : ~~K-means clustering~~

하다 보면 늘어요!
이제 눈 대중으로만 봐도
품종, 사이즈, 가격을 맞춰요!

5> 1단계 : 조건 지정

생선 길이가 30cm 이상이면 면 도미입니다

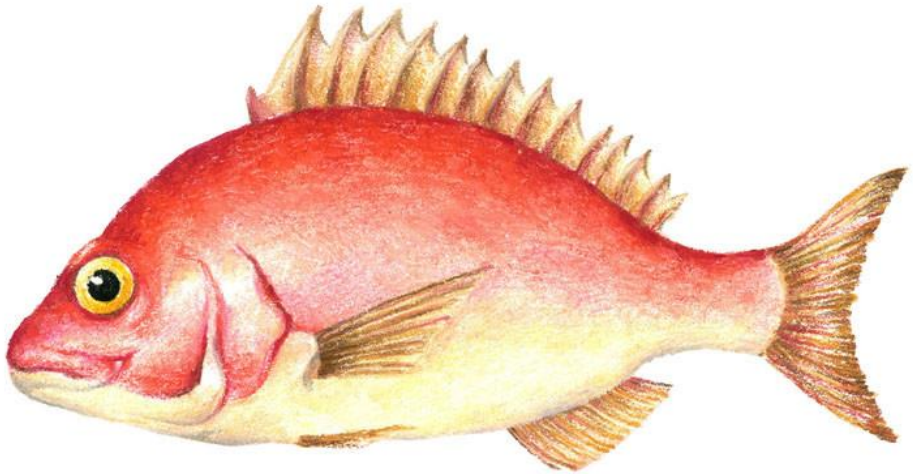

5> 1단계 : 조건 지정

```
if fish_length >=30 :
Print(“도미”)
```

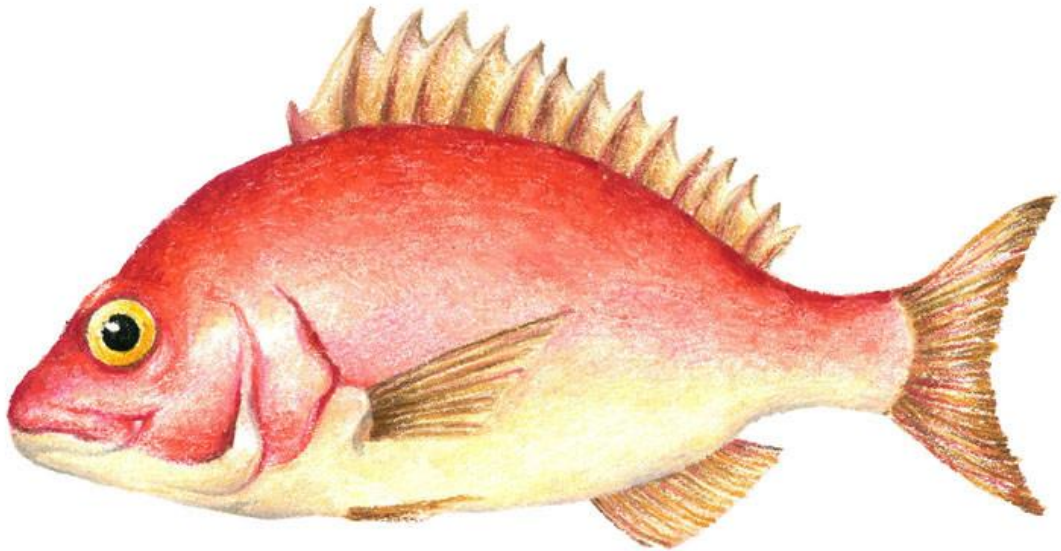

5> 1단계 : 조건 지정

```
if fish_length >=30 :
Print("도미")
```

생각해볼 문제 : 조건식만으로는 아무 것도 못한다

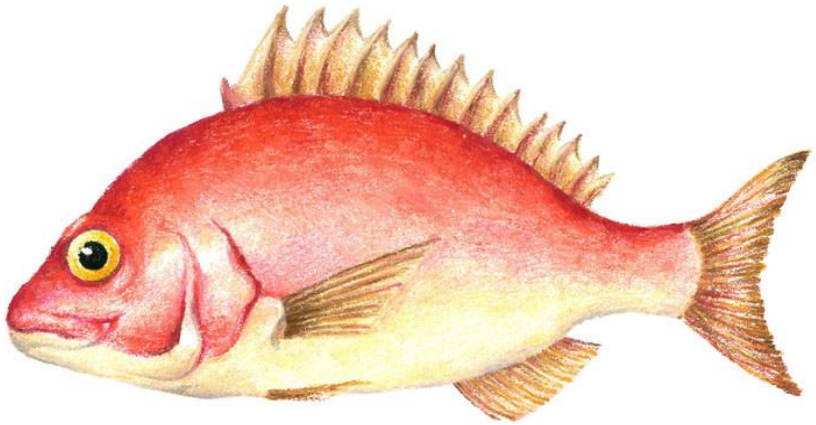

무엇이 필요할까요?

1> 생선 데이터가 필요합니다.
2> 생선 데이터를 불러와야 합니다.
3> 생선 데이터 중에 길이 값이 필요합니다.
4> 생선 데이터 중에 길이 값 단위는 "cm"
5> 생선 데이터 중에 길이 값의 이름은 fish_length

5> 1단계 : 조건 지정

```
if fish_length >=30 :
Print(“도미”)
```

또 생각해볼 문제 :
하나의 조건만으로는 판단하기 어렵다.

생선의 길이 외에 다른 조건이 필요하다.

+ 생선의 무게(kg)도 고려함

5> 1단계 : 조건 지정

6> 데이터 입력

- 코랩에서 방 이름 바꾸기

6> 데이터 입력

- 코랩에서 방만들기

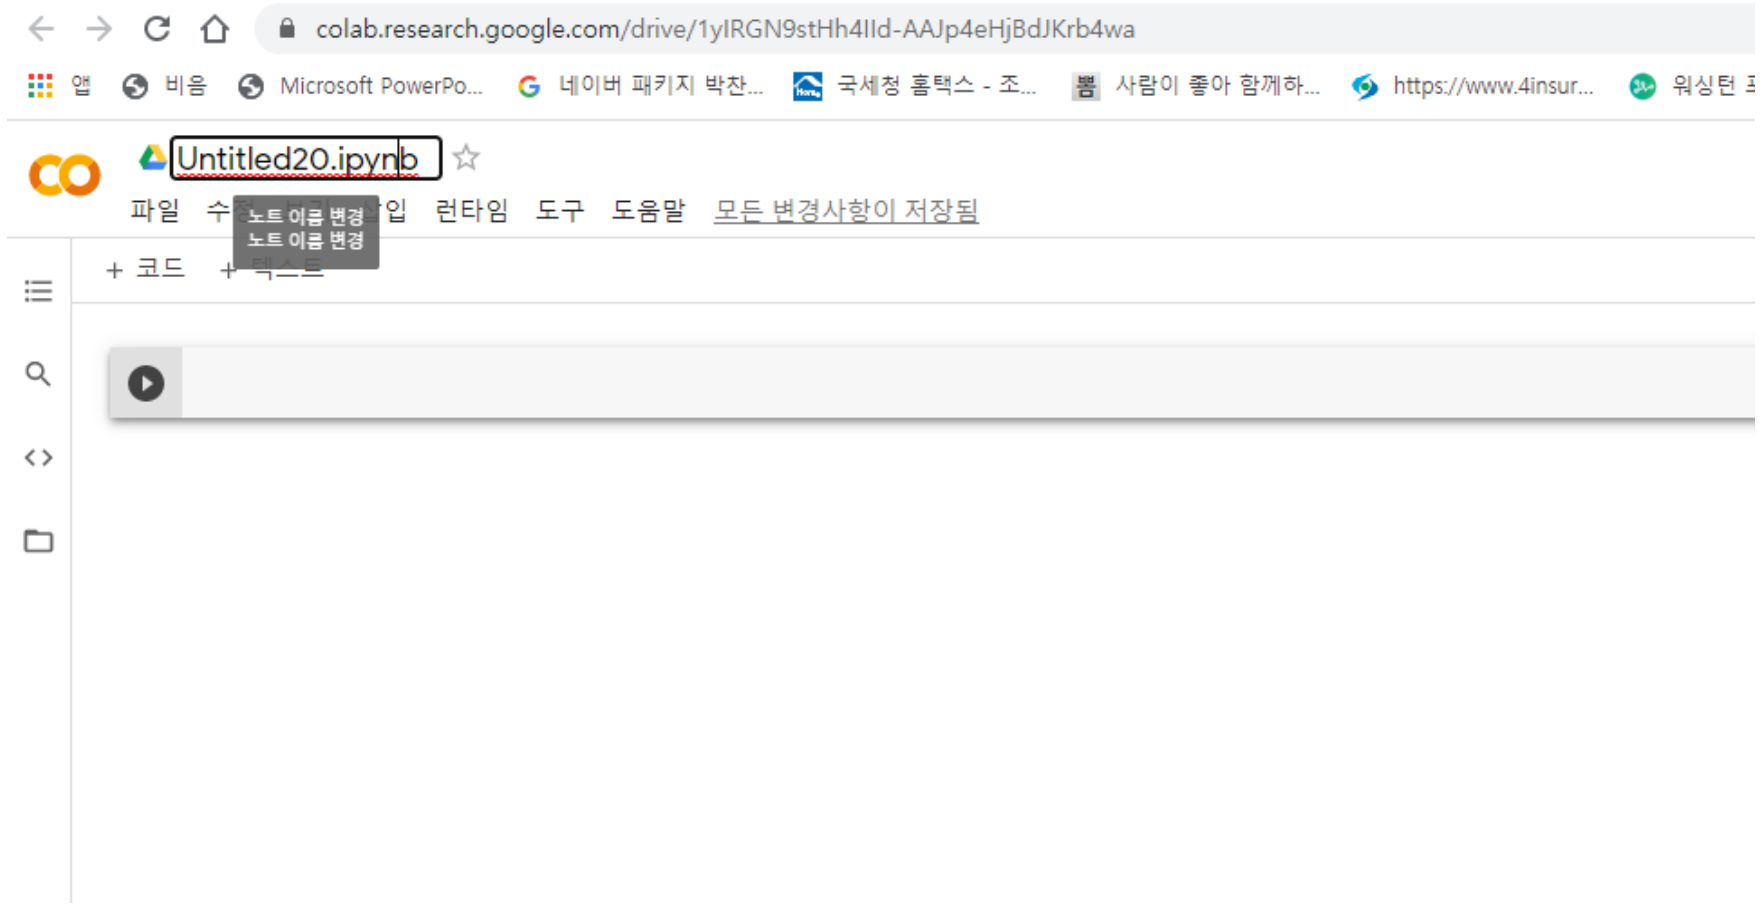

6> 데이터 입력

- 파이썬에서 데이터 입력

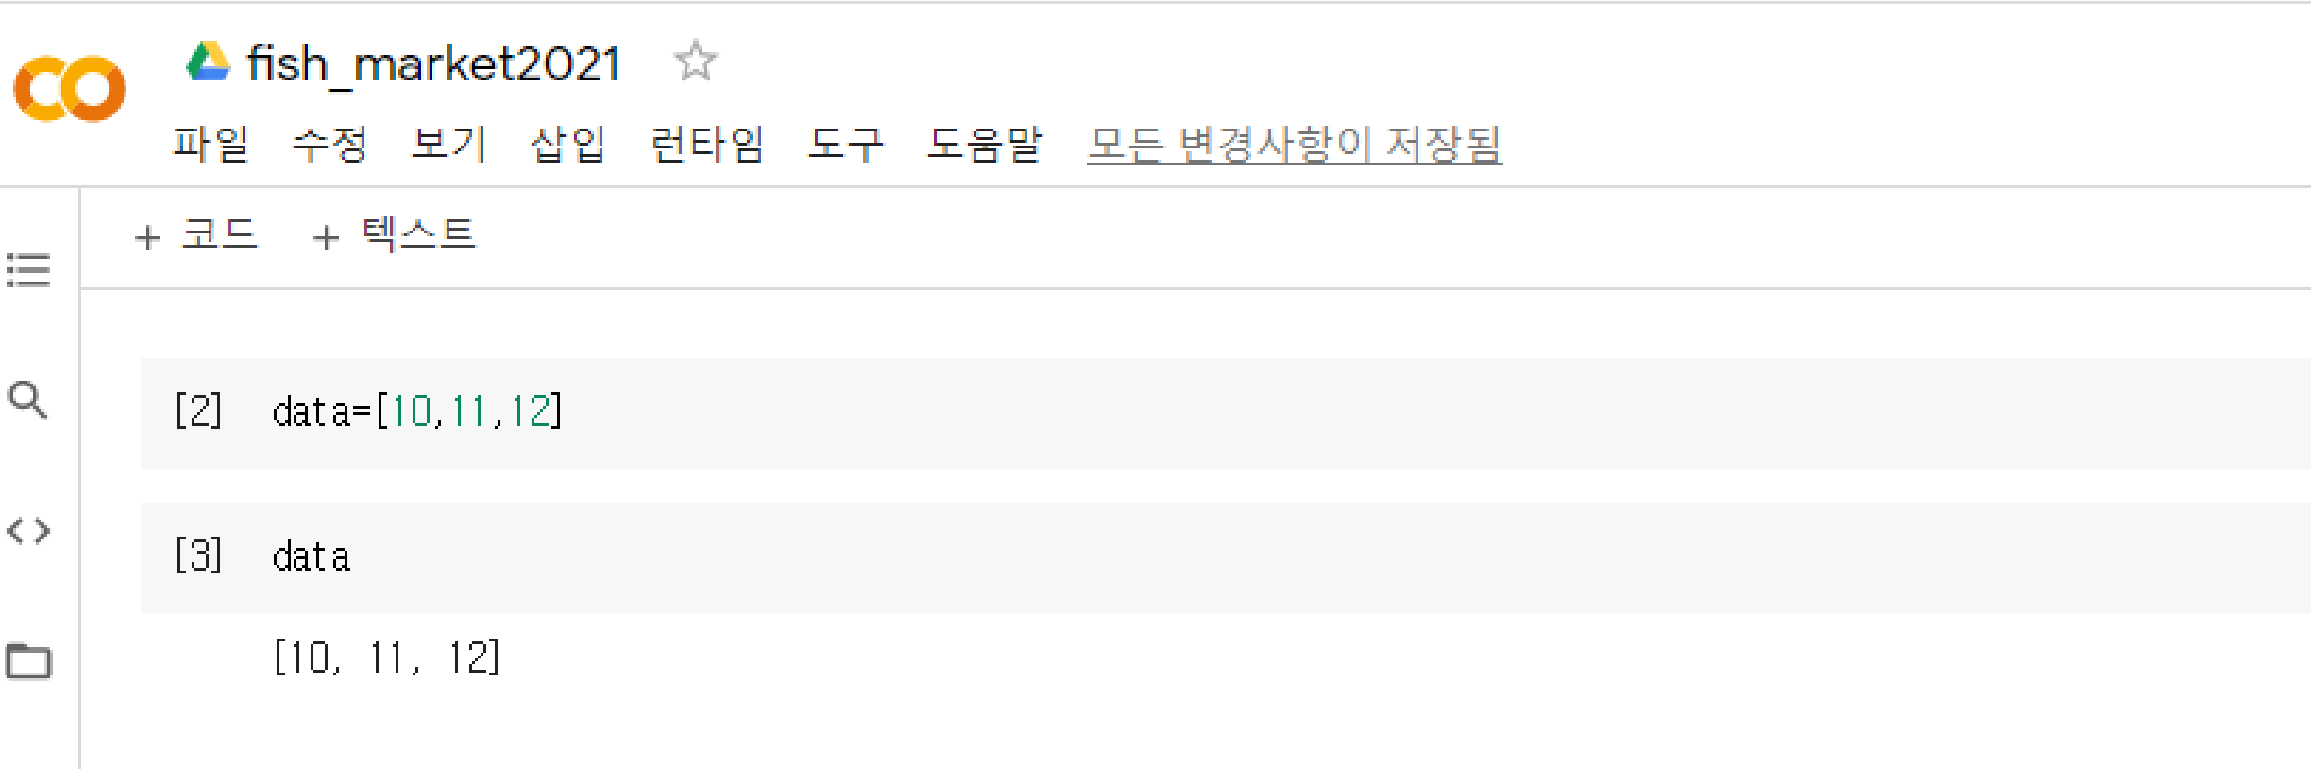

6> 데이터 입력

- 파이썬에서 데이터 입력

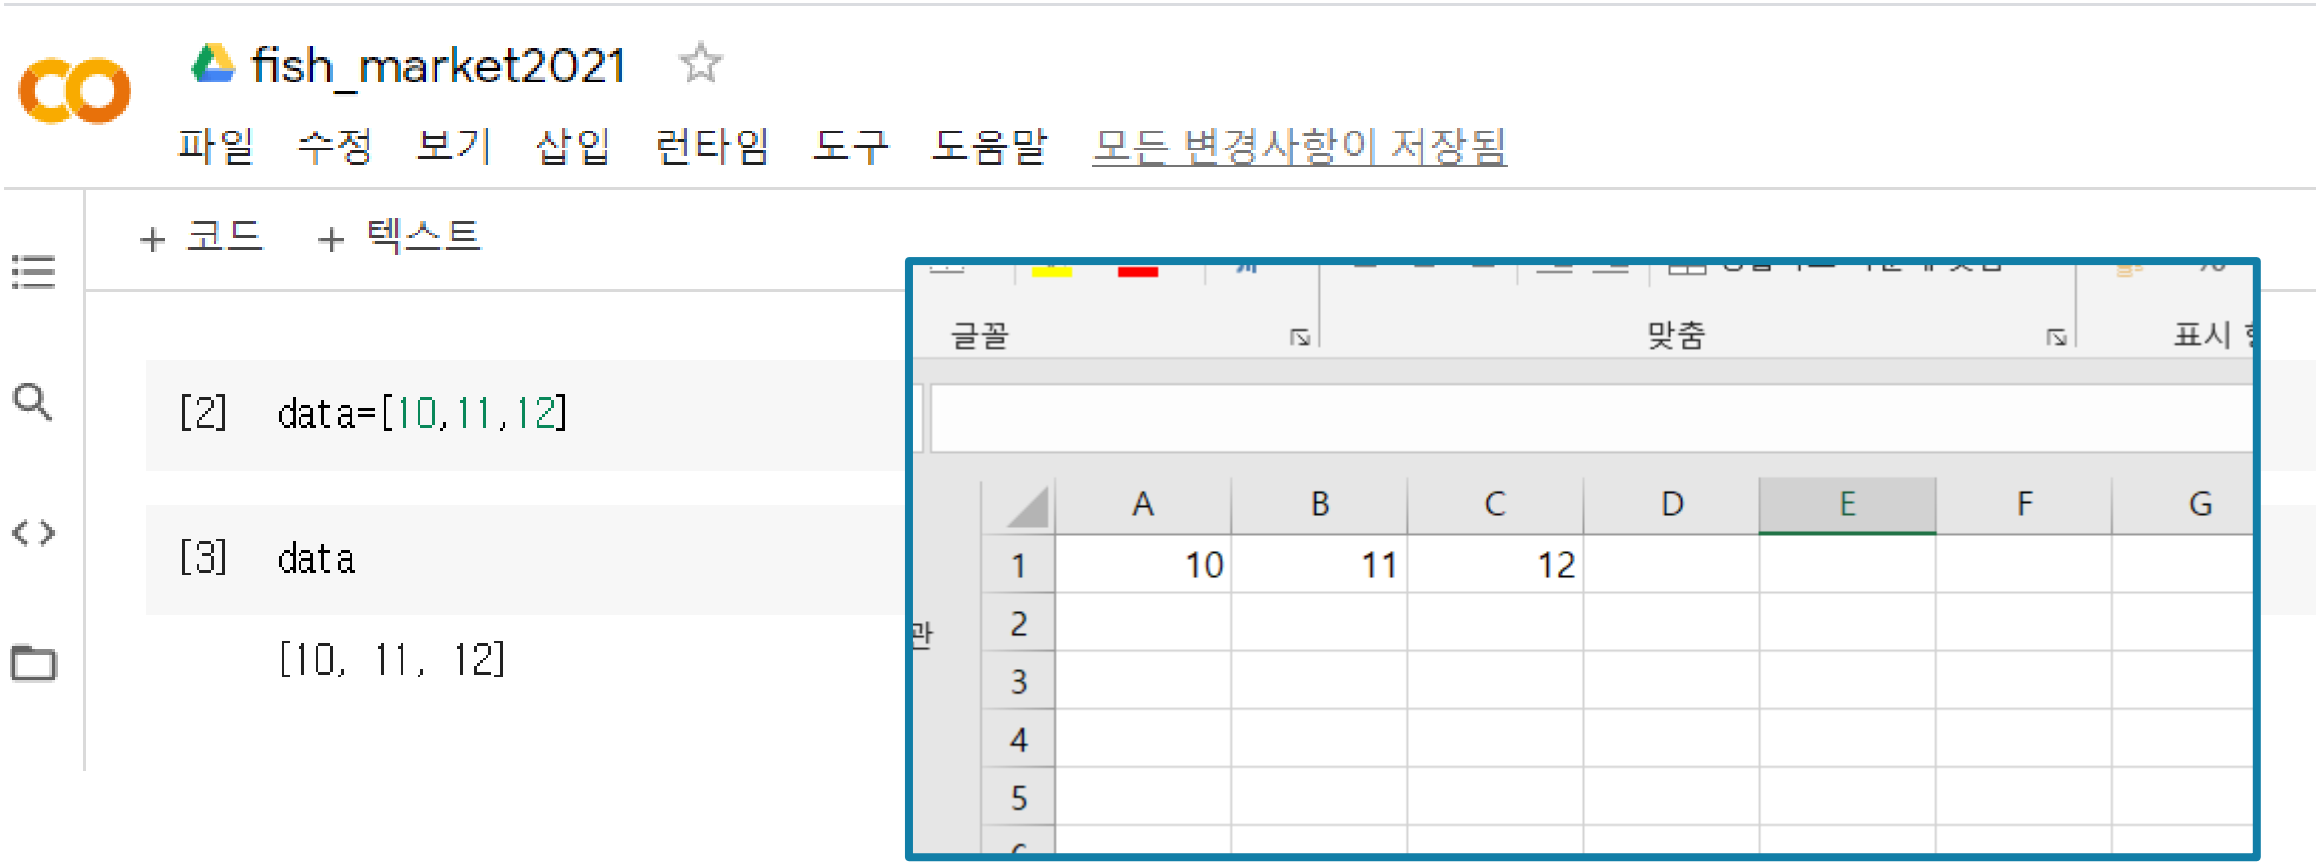

6> 데이터 입력

- 파이썬에서 데이터 입력

: 아래 값을 bream_length라는 변수로 입력해 보세요

[23.2, 24, 23.9, 26.3, 26.5, 26.8, 26.8, 27.6, 27.6, 28.5, 28.4, 28.7, 29.1, 29.5, 29.4, 29.4, 30.4, 30.4, 30.9, 31, 31.3, 31.4, 31.5, 31.8, 31.9, 31.8, 32, 32.7, 32.8, 33.5, 35, 35, 36.2, 37.4, 38]

* bream(도미)

6> 데이터 입력

- 파이썬에서 데이터 입력

: 아래 값을 bream_weight라는 변수로 입력해 보세요

[242, 290, 340, 363, 430, 450, 500, 390, 450, 500, 475, 500, 500,
340, 600, 600, 700, 700, 610, 650, 575, 685, 620, 680, 700, 725,
720, 714, 850, 1000, 920, 955, 925, 975, 950]

* bream(도미)

6> 데이터 입력

- 무게와 크기를 입력한 값이 모두 몇 개인가요?

명령어 : len(데이터 셀 이름)

입력 값

len(bream_length)
len(bream_weight)

6> 데이터 입력 (아웃풋)

```
[9] bream_length=[23.2, 24, 23.9, 26.3, 26.5, 26.8, 26.8, 27.6, 27.6, 28.5, 28.4, 28.7, 29.1, 29.5, 29.4, 29.4, 30.4, 30.4, 30.9, 31, 31.3, 31.4, 31.5, 31.8, 31.9, 31.8, 32, 32.7, 32.8, 33.5, 35, 35, 36.2, 37.4, 38]
```

```
bream_length
```

```
[23.2,
 24,
 23.9,
 26.3,
 26.5,
 26.8,
 26.8,
 27.6,
 27.6,
 28.5,
 28.4,
 28.7,
 29.1,
 29.5,
 29.4,
 29.4,
 30.4,
 30.4,
 30.9,
 31,
 31.3,
 31.4,
 31.5,
 31.8,
 31.9,
 31.8,
 32,
 32.7,
 32.8,
 33.5,
 35,
 35,
 36.2,
 37.4,
 38]
```

6> 데이터 입력 (아웃풋)

```
[14]  bream_weight
```

```
[242,
 290,
 340,
 363,
 430,
 450,
 500,
 390,
 450,
 500,
 475,
 500,
 500,
 340,
 600,
 600,
 700,
 700,
 610,
 650,
 575,
 685,
 620,
 680,
 700,
 725,
 720,
 714,
 850,
 1000,
 920,
 955,
 925,
 975,
 950]
```

6> 데이터 입력 (아웃풋)

```
[15] len(bream_length)
```

```
35
```

```
[16] len(bream_weight)
```

```
35
```

7> 데이터를 표현해 보기 (아웃풋)

데이터를 보겠습니다. 잘 보이십니까?

	sepal length (cm)	sepal width (cm)	petal length (cm)	petal width (cm)	target
0	5.1	3.5	1.4	0.2	0.0
1	4.9	3.0	1.4	0.2	0.0
2	4.7	3.2	1.3	0.2	0.0
3	4.6	3.1	1.5	0.2	0.0
4	5.0	3.6	1.4	0.2	0.0
5	5.4	3.9	1.7	0.4	0.0
6	4.6	3.4	1.4	0.3	0.0
7	5.0	3.4	1.5	0.2	0.0
8	4.4	2.9	1.4	0.2	0.0
9	4.9	3.1	1.5	0.1	0.0
10	5.4	3.7	1.5	0.2	0.0
11	4.8	3.4	1.6	0.2	0.0
12	4.8	3.0	1.4	0.1	0.0
13	4.3	3.0	1.1	0.1	0.0
14	5.8	4.0	1.2	0.2	0.0

4 Features
4 Dimensions

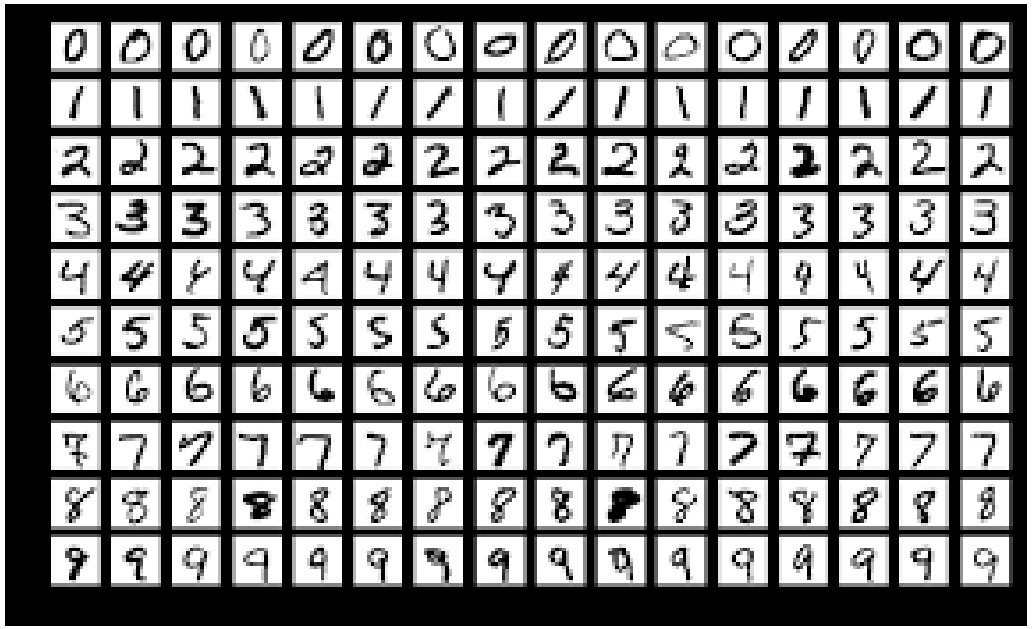

7> 데이터를 표현해 보기 (아웃풋)

데이터를 '한 눈'에 보고 싶습니다 : 시각화

7> 데이터를 표현해 보기 (아웃풋)

도미의 무게(x)와 크기(y)의 관계를 보겠습니다!

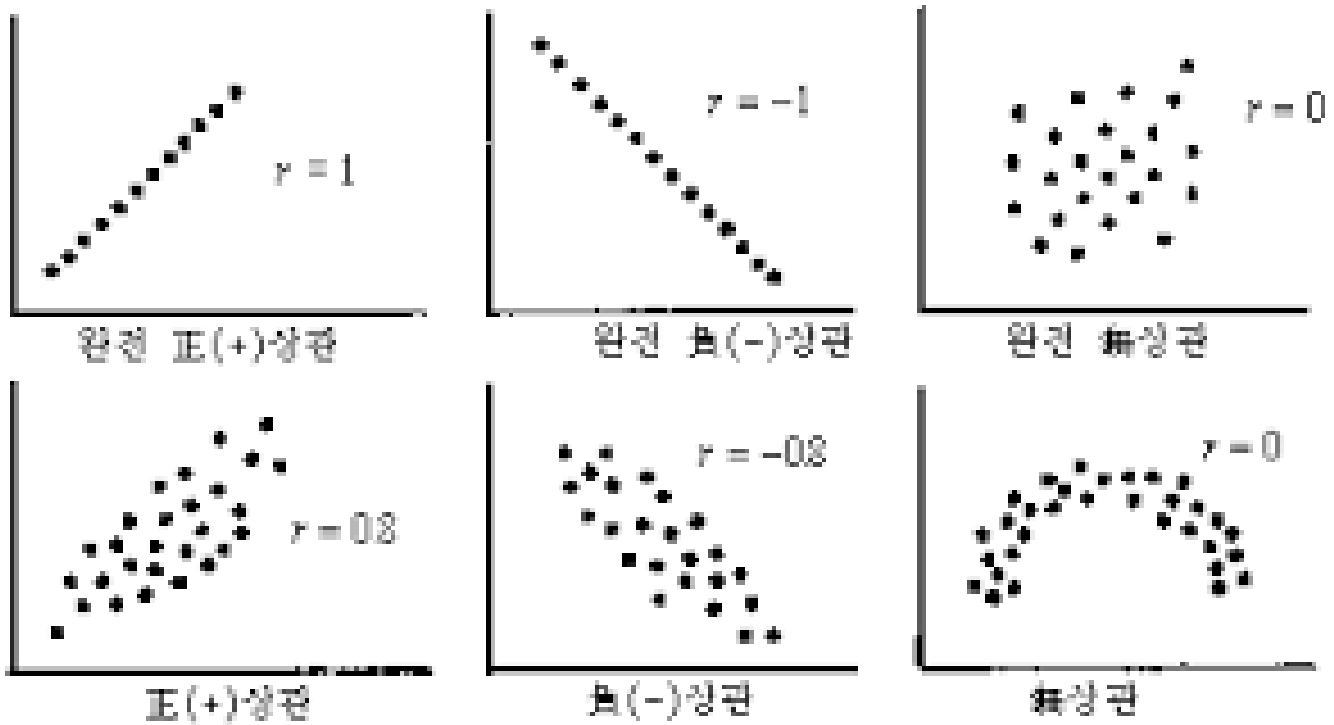

7> 데이터를 표현해 보기 (아웃풋)

```
plt.scatter(bream_length, bream_weight)
plt.xlabel('length')
plt.ylabel('weight')
plt.show()
```

7> 데이터를 표현해 보기 (아웃풋)

```
import matplotlib.pyplot as plt
#함수를 부릅니다.
# 그리고 matplolib의 pylot함수를 plt로 줄여서 사용
plt.scatter(bream_length, bream_weight)
plt.xlabel('length')
plt.ylabel('weight')
plt.show()
```

7> 데이터를 표현해보기

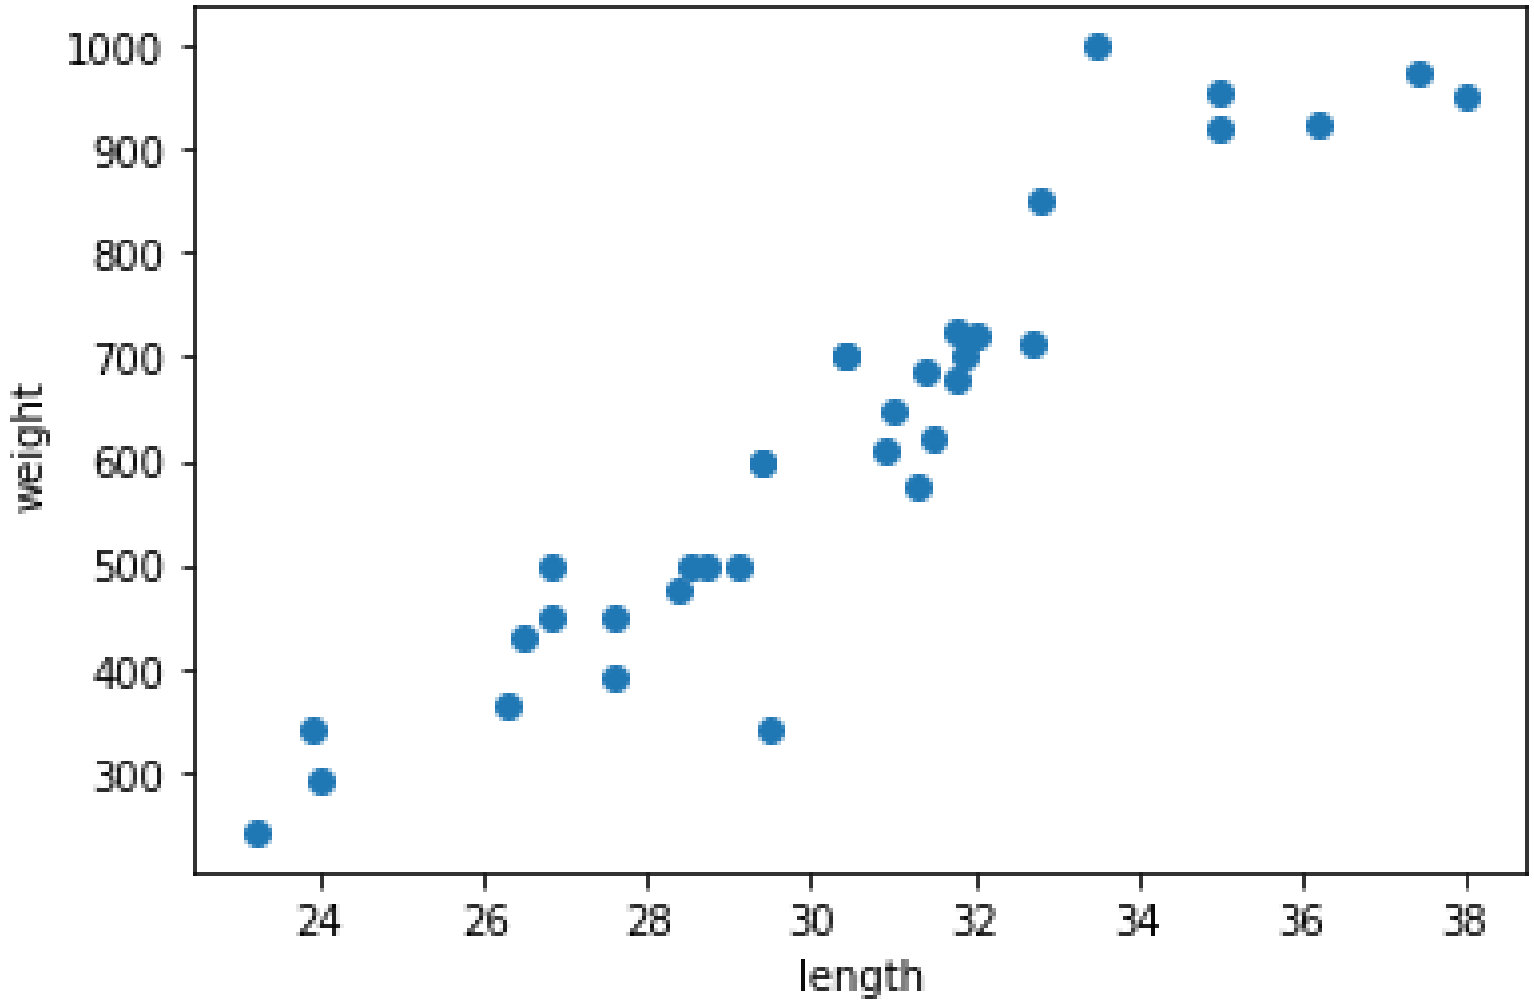
1000
900
800
700
600
500
400
300
weight
24
26
28
30
32
34
36
38
length

7> 데이터를 표현해 보기

- 실제 작업 : 데이터를 pair로 묶고 좌표를 찍음

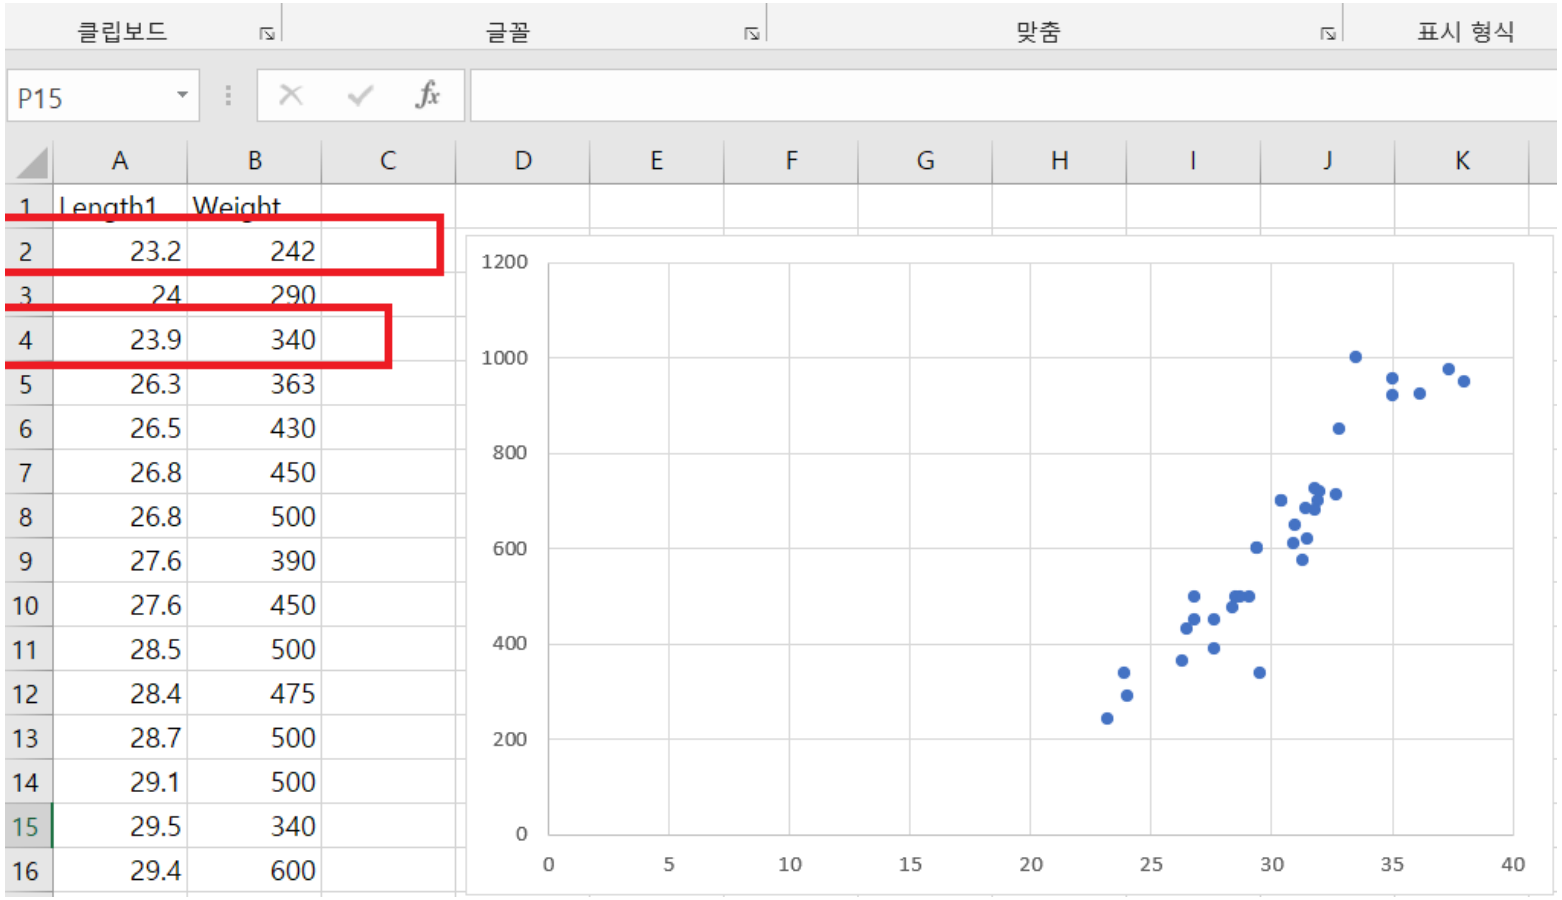

7> 추가 데이터 입력 및 시각화

- 빙어(smelt) 데이터 입력 : 총 14마리

- 빙어의 길이(length)

9.3, 10, 10.1, 10.4, 10.7, 10.8, 11.3, 11.3, 11.4, 11.5, 11.7,

12.1, 13.2, 13.8

- 빙어의 무게(weight)

6.7, 7.5, 7.0, 9.7, 9.8, 8.7, 10, 9.9, 9.8, 12.2. 13.4, 12.2,

19.7, 19.9

8> 데이터 표현해 보기 (아웃풋)

```
[25] smelt_length=[9.3, 10, 10.1, 10.4, 10.7, 10.8, 11.3, 11.3, 11.4, 11.5, 11.7, 12.1, 13.2, 13.8]
     len(smelt_length)
```

```
14
```

```
[29] smelt_weight=[6.7, 7.5, 7.0, 9.7, 9.8, 8.7, 10.0, 9.9, 9.8, 12.2, 13.4, 12.2, 19.7, 19.9]
     len(smelt_weight)
```

```
14
```

8> 데이터 표현해 보기 (아웃풋)

```
[25] smelt_length=[9.3, 10, 10.1, 10.4, 10.7, 10.8, 11.3, 11.3, 11.4, 11.5, 11.7, 12.1, 13.2, 13.8]
     len(smelt_length)
```

```
14
```

```
[29] smelt_weight=[6.7, 7.5, 7.0, 9.7, 9.8, 8.7, 10.0, 9.9, 9.8, 12.2, 13.4, 12.2, 19.7, 19.9]
     len(smelt_weight)
```

```
14
```

8> 데이터 표현해 보기 (아웃풋)

```
[31]  import matplotlib.pyplot as plt #matplolib의 pylot함수를 plt로 줄여서 사용
```

```
plt.scatter(smelt_length, smelt_weight)
plt.xlabel('length')
plt.ylabel('weight')
plt.show()
```

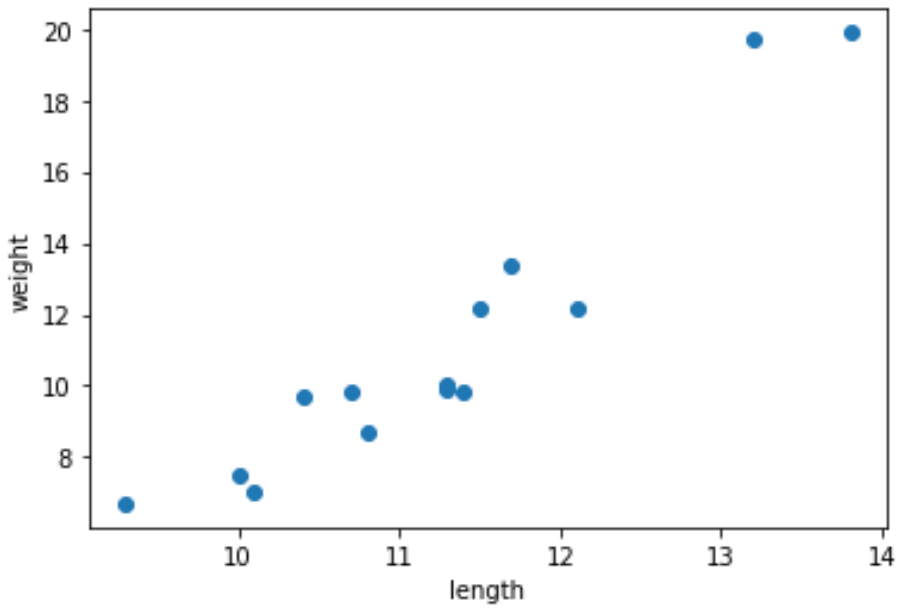

9> 머신러닝 프로그램을 위한 데이터 합치기

#1 데이터 합치기

length=bream_length+smelt_length

weight=bream_weight+smelt_weight

#2 합친 개수 확인

len(length), len(weight)

9> 머신러닝 프로그램을 위한 데이터 합치기

#3 데이터 합치기

```
fish_data=[[l,w] for l, w in zip(length, weight)]
print(fish_data)
```

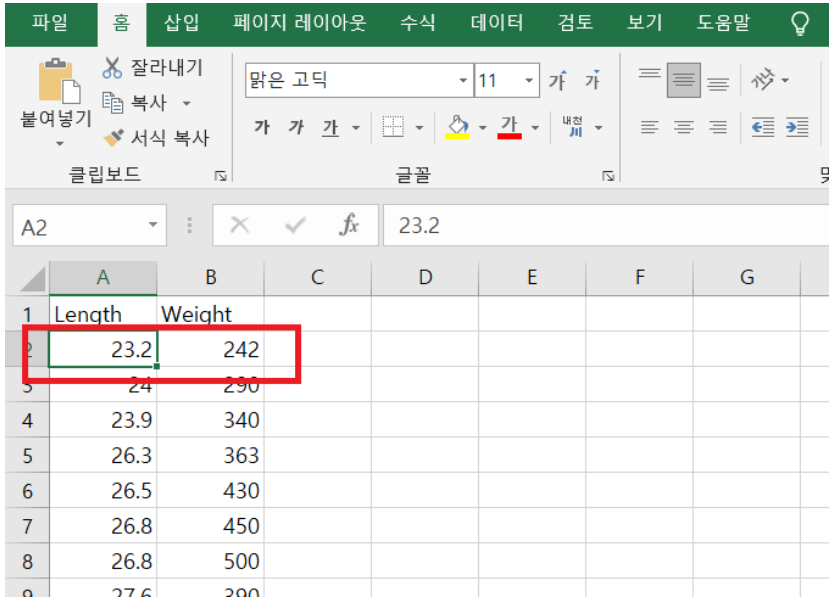

9> 머신러닝 프로그램을 위한 데이터 합치기

#2 결과

```
[38] length=bream_length+smelt_length
     weight=bream_weight+smelt_weight
     len(length), len(weight)
```

```
(49, 49)
```

```
[41] fish_data=[[l,w] for l, w in zip(length, weight)]
```

```
[42] print(fish_data)
```

```
[[23.2, 242], [24, 290], [23.9, 340], [26.3, 363], [26.5, 430], [26.8, 450], [26.8, 500], [27.6, 390], [27.6, 450], [28.5, 500], [28.4, 475], [28.7, 500], [29.
```

9> 머신러닝 프로그램을 위한 데이터 합치기

#4 라벨링

1번 부터 35번은 1번(도미), 36번 부터 49번까지는 0번(빙어)

```
fish_target=[1]*35+[0]*14
print(fish_target)
```

9> 머신러닝 프로그램을 위한 데이터 합치기

#4 라벨링

```
[42] print(fish_data)
```

```
[[23.2, 242], [24, 290], [23.9, 340], [26.3, 363], [26.5, 430], [26.8, 450], [26.8, 500], [27.6, 390], [27.6, 450], [28.5, 500], [28.4, 475], [28.7, 500], [29.1, 5
```

```
fish_target=[1]*35+[0]*14
print(fish_target)
```

```
[1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0]
```

10> 머신러닝

*컨셉

	A	B	C	D	E	F
1	Length	Weight	target			
2	23.2	242	1			
3	24	290	1			
4	23.9	340	1			
5	26.3	363	1			
6	26.5	430	1			
7	26.8	450	1			
8	26.8	500	1			
9	27.6	390	1			
10	27.6	450	1			
11	28.5	500	1			
12	28.4	475	1			
13	28.7	500	1			
14	29.1	500	1			
15	29.5	340	1			
16	29.4	600	1			

10> 머신러닝 실행

*컨셉

	A	B	C	D	E	F
1	Length	Weight				
2	23.2	242				
3	24	290				
4	23.9	340				
5	26.3	363				
6	26.5	430				
7	26.8	450				
8	26.8	500				
9	27.6	390				
10	27.6	450				
11	28.5	500				
12	28.4	475				
13	28.7	500				
14	29.1	500				
15	29.5	340				
16	29.4	600				

10> 머신러닝 실행

*컨셉

	A	B	C	D	E	F
1	Length	Weight				
2	23.2	242	1			
3	24	290	1			
4	23.9	340	1			
5	26.3	363	1			
6	26.5	430	1			
7	26.8	450	1			
8	26.8	500	1			
9	27.6	390	1			
10	27.6	450	1			
11	28.5	500	1			
12	28.4	475	1			
13	28.7	500	1			
14	29.1	500	1			
15	29.5	340	1			
16	29.4	600				

10> 머신러닝 실행

*컨셉

	A	B	C	D	E	F
1	Length	Weight	target			
2	23.2	242	1			
3	24	290	1			
4	23.9	340	1			
5	26.3	363	1			
6	26.5	430	1			
7	26.8	450	1			
8	26.8	500	1			
9	27.6	390	1			
10	27.6	450	1			
11	28.5	500	1			
12	28.4	475	1			
13	28.7	500	1			
14	29.1	500	1			
15	29.5	340	1			
16	29.4	600	1			

1
1
1
1
1
1
1
1
1
1
1
1
1
1
1

10> 머신러닝 실행

```
from sklearn.neighbors import KNeighborsClassifier
#from sklearn이라는 패키지에서 KNeighborsClassifier 사용

Kn=KNeighborsClassifier()
#훈련을 하기 위한 객체 생성

kn.fit(fish_data, fish_target)
# 훈련 시작

kn.score(fish_data,fish_target)
# 평가
```

10> 머신러닝 실행

```
[45] from sklearn.neighbors import KNeighborsClassifier
```

```
[46] kn=KNeighborsClassifier()
```

```
[47] kn.fit(fish_data, fish_target)
```

```
KNeighborsClassifier(algorithm='auto', leaf_size=30, metric='minkowski',
                     metric_params=None, n_jobs=None, n_neighbors=5, p=2,
                     weights='uniform')
```

```
[48] kn.score(fish_data,fish_target)
```

```
1.0
```

11> 맞춰보기

길이가 30cm이고 무게가 600g이면 무엇인가요?

```
kn.predict([[30,600]])
#길이 30cm, 무게 600g 이면 무엇인가요?
```

```
[50] kn.predict([[30,600]])

     array([1])
```

11> 머신러닝의 평가

: 도미(bream), 빙어(smelt)를 시각화 하고, 길이30cm

무게600g인 물고기를 표시

```
plt.scatter(bream_length, bream_weight)
plt.scatter(smelt_length, smelt_weight)
plt.scatter(30,600, marker='^')
plt.xlabel('length')
plt.ylabel('weight')
plt.show()
```

11> 머신러닝의 평가

: 도미(bream), 빙어(smelt)를 시각화 하고, 길이30cm

무게600g인 물고기를 표시

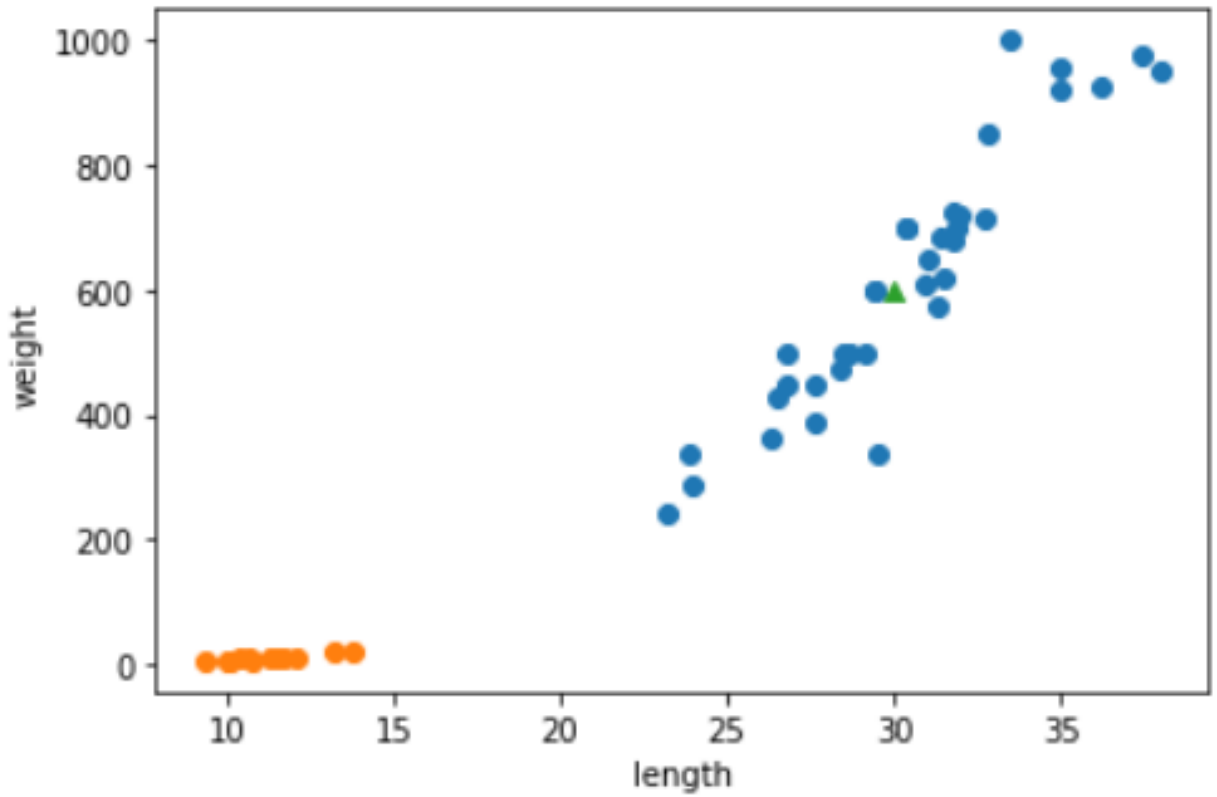

Chapter03 : Q&A